

日频文本因子策略 · 项目复盘

一、起点问题

- 原 `gru.ipynb` 直接用现成的 4096 维嵌入喂 GRU，无法得知怎么降维。
- 评估用 MSE，不符合截面选股口径（应该看 IC）。
- 切训练/验证/测试前就做了降维和归一化，未来标签泄漏进训练集。

二、整体思路

- 把流程拆成三段：**文本日频化** → **嵌入降维** → **因子模型**，每段单独可调试。
- 评估口径换成截面 IC / RankIC / ICIR + 分位多空 Sharpe。

三、阶段1：文本日频化

- 多篇研报/新闻按 (交易日, 股票) 拼成单条长文本，超长截断。
- LLM 把全文压到 300-500 字摘要：省嵌入成本、去噪。
- 质检：同一嵌入器编码全文与摘要，看余弦相似度分布，低于阈值的 flag 出来。
- 深层质检留到第三阶段：「全文 vs 摘要」各跑一遍看 IC 是否打平。
- 目前研报是使用llm合成的，稍后会用xr姐给的接口跑真研报，验证合成数据的代表性。

四、阶段2：嵌入 + 有监督降维

- FinBERT（实际用回退的 `bert-base-chinese`）出 768 维句向量。
- 用 BERTopic + UMAP 压到 10 维。
- 关键：**有监督**——降维时把训练期标签告诉模型，让保留方向偏向收益相关。
- 必须只在训练期 fit，再 transform 全样本，否则就是泄漏。

五、阶段3：GRU + LightGBM

- 每只股票按时间排序列，GRU 抽时序特征，LGBM 在特征上做截面打分。
- 截面 z-score：去掉市场整体水位影响。
- 段间 purge：宽度等于 label 前瞻长度，防标签窗口跨段重叠。
- 输出：逐日 IC、ICIR、Top-Bottom 多空净值、年化 Sharpe。

六、当前状态

- 快速通道：`dt_lgbm.parquet` × 430 股票，test 多空 Sharpe ≈ 1.37 。
- 文本路径：合成数据股票太少，Stage 3 IC 表空，这是数据规模问题不是代码问题。

七、下一步

1. 合成扩到 30+ 只股票，证明文本路径在合理规模下也能出非空 IC。
2. 换真研报 parquet，列名对齐即可，无需改代码。
3. 跑「全文 vs 摘要」对比，看摘要是否保住 alpha。
4. 打开 `oof_gru_features=True`，验证 GRU→LGBM 堆叠泄漏的影响。