

# 研报文本因子流水线 · 模型构建与实验进展报告

日期：2026-06-01

**一句话摘要：**端到端流水线已跑通，但样本外 IC 始终在零附近波动，原因是**月频评估窗口样本量过小、统计功效不足**，而非模型或符号错误。已用平台日频数据验证**改周频可恢复功效**，下一步据此重建评估频率。

## 1. 项目目标与模型架构

**目标：**把 A股研报文本转化为可用于选股的跨截面因子，并以严格的样本外（OOS）口径评估其有效性（IC / RankIC / ICIR / 多空夏普）。

**四阶段流水线：**

| 阶段          | 模块            | 职责                                                       |
|-------------|---------------|----------------------------------------------------------|
| Stage 1a/1b | 文本日频化 + 摘要    | 研报库 → (交易日,股票) 去重聚合 → 300-500字摘要                         |
| Stage 2     | 嵌入 + 有监督降维    | FinBERT(bert-base-chinese) 768维 → 仅train拟合的有监督UMAP → 10维 |
| Stage 3     | GRU + LGBM 因子 | GRU序列特征 → LGBM → 截面因子 + IC/多空回测                          |
| 对照          | 全文 vs 摘要      | 闭环验证摘要是否丢失 alpha                                         |

**数据口径（关键）：**标签源 `dt_lgbm.parquet` 为月频，面板共 68 个月度截面、372 只研报覆盖股，每截面平均仅约 116 只有文本。

## 2. 实验过程（按时间顺序）

### 2.1 基线流水线跑通

完成 Stage1→3 全链路。文本压成 10 维特征后喂入 LGBM，并与"裸 4096 维嵌入直喂 Stage3"的快速通道对比。

### 2.2 直接 LGBM 基线（direct\_lgbm）实测结果

| 数据段   | IC_mean | RankIC_mean | ICIR   | 截面数 | t 值   |
|-------|---------|-------------|--------|-----|-------|
| train | +0.1956 | +0.1906     | +1.598 | 35  | +9.45 |
| valid | -0.0154 | -0.0288     | -0.192 | 14  | -0.72 |
| test  | +0.0161 | +0.0191     | +0.213 | 17  | +0.88 |

**解读：**train 强正 (t=9.45) 但 valid/test 的 |t|<2，与 0 无差异。train 的高 IC 是"有监督降维用未来收益分位拟合 train 标签"的产物，不代表泛化能力。

2.3 滚动窗口（cons\_roll）与全文/摘要对照

| 实验                   | test IC         | test ICIR       | 多空夏普  |
|----------------------|-----------------|-----------------|-------|
| cons_roll_2023_04    | -0.0226         | -0.220          | +0.14 |
| cons_roll_2023_10    | -0.0273         | -0.264          | -0.46 |
| cons_roll_2024_04    | +0.0066         | +0.089          | +1.75 |
| full_text vs summary | -0.017 / -0.015 | -0.166 / -0.141 | —     |

**解读：**test IC 符号在窗口间随机翻转；full\_text 与 summary 两种文本口径 OOS 都  $\approx -0.015$ 。这排除了"符号学反"（train 强正），指向 OOS 根本无可辨识信号。

2.4 受控诊断：信号到底在哪一层丢失（diag\_signal）

用与真实流水线相同的 purged 切分 + IC 计算代码，逐层消融：

| 实验             | valid IC (t)    | test IC (t)     | 判定           |
|----------------|-----------------|-----------------|--------------|
| 正控制（标签+噪声）     | +0.995 (t=2760) | +0.994 (t=1812) | 评估/对齐代码正确    |
| 负控制（纯噪声）       | -0.018 (-0.63)  | +0.026 (+0.89)  | 噪声基准         |
| raw 768维 + 岭回归 | +0.004 (0.11)   | -0.001 (-0.02)  | 零信号          |
| 无监督 PCA 10维    | -0.032 (-1.06)  | +0.048 (+1.09)  | 零信号          |
| 有监督 UMAP 10维   | -0.005 (-0.13)  | +0.060 (+2.00)  | $\approx$ 噪声 |

关键结论：

- 1. 正控制  $t \approx$  千级  $\rightarrow$  评估/对齐/purge 代码无误，负 IC 是真实数据而非 bug；
- 2. 任何文本表示（原始768/PCA/有监督UMAP）OOS  $|t|$  均  $< 2$ ，与纯噪声无法区分  $\rightarrow$  不是降维/调参问题；
- 3. 有监督 UMAP 的 OOS 并不优于原始，印证 train IC 是泄漏式拟合产物。

2.5 天花板测试：评估窗口有没有统计功效（diag\_ceiling）

引入平台量价数据，用公认强因子检验当前月频窗口能否测出任何因子。（test 段 17 个月度截面，372 股）

| 因子          | test IC (t)       | 因子            | test IC (t)       |
|-------------|-------------------|---------------|-------------------|
| 动量 mom_12_1 | -0.0155 (t=-0.32) | 流动性 liq_amt20 | -0.0310 (t=-1.02) |
| 反转 rev_1m   | +0.0153 (t=0.30)  | 换手率 turn_20   | -0.0387 (t=-1.07) |
| 波动率 vol_60  | -0.0278 (t=-0.45) | 小市值 size      | +0.0158 (t=0.36)  |

**决定性结论：**连换手率、小市值、波动率这些 A股最强因子，在该月频窗口里  $|t|$  全部  $< 2$  —— 评估窗口本身没有分辨力。之前文本因子的"负 IC"只是这个无功效窗口里的噪声。

2.6 周频验证：改频率能否恢复功效（diag\_weekly\_ceiling）

用平台日频价格自建周频截面（test 段 70 个截面）+ 未来1周收益标签，重跑同样因子：

| 因子            | 月频 test t | 周频 test t（全市场） | 是否显著 |
|---------------|-----------|----------------|------|
| 流动性 liq_amt20 | -1.02     | -3.09          | ✓ 显著 |
| 小市值 size      | +0.36     | +2.29          | ✓ 显著 |
| 反转 rev_1w     | —         | +1.65          | 接近   |
| 换手率 turn_20   | -1.07     | -1.20          | 改善   |

**验证成立：**截面数 17→70 后，多个强因子 |t| 升破 2，符号在 train/valid/test 三段一致。证明瓶颈是评估频率太粗，t 值随 √截面数 放大的规律完全兑现。

已据此构建周频标签源 `weekly_labels.parquet`（326 个周度截面，未来1周 vwap 收益 + 横截面分位）。

### 3. 当前遇到的核心问题

| # | 问题                | 证据 / 影响                                    |
|---|-------------------|--------------------------------------------|
| 1 | 月频评估无统计功效         | 强因子  t  全<2；test 仅 17 截面，结构上测不出常规因子        |
| 2 | train IC 失真，无诊断价值 | 有监督降维用未来分位拟合 train 标签，train IC 0.196 是泄漏产物 |
| 3 | 文本特征 OOS 无可测信号    | 原始768/PCA/UMAP 的 OOS  t  均<2，与噪声无异         |
| 4 | 研报覆盖稀疏            | 68 截面、每截面仅约 116 股有文本，改周频后文本新鲜度被稀释          |
| 5 | 文本票池压制因子上限        | 372 只研报覆盖股多为大盘低换手，因子区分度天然弱于全市场             |

### 4. 下一步方案

**总原则：**先把"评估"修到有功效，再回头判断文本因子真伪 —— 在无功效的窗口里调模型等于在噪声里调参。

| 优先级    | 动作              | 目的                |
|--------|-----------------|-------------------|
| P0 已完成 | 天花板测试 + 周频验证    | 确认根因=评估频率，而非模型/符号 |
| P1 进行中 | 评估频率改周频（标签源已建好） | 截面数 17→70，恢复统计功效  |

### 附录：相关脚本

| 脚本                                                | 作用                                         |
|---------------------------------------------------|--------------------------------------------|
| <code>pipelines/diag_signal.py</code>             | 逐层消融：正/负控制 + 各文本表示的 OOS IC                 |
| <code>pipelines/diag_ceiling.py</code>            | 月频天花板：量价强因子在当前窗口的可测性                       |
| <code>pipelines/diag_weekly_ceiling.py</code>     | 周频验证：改频率后功效是否恢复                            |
| <code>pipelines/build_weekly_labels.py</code>     | 构建周频标签源 <code>weekly_labels.parquet</code> |
| <code>pipelines/export_platform_factors.py</code> | 平台机取数（量价 + Barra 暴露）                       |